



PUC Minas Pontifícia Universidade Católica de Minas Gerais
ICEI - Curso de Ciência da Computação
Disciplina: Processamento e Análise de Imagens
Prof. Alexei Machado

Trabalho Prático

Diagnóstico de Esteatose Hepática em Exames de Ultrassom

Data de entrega: 20/10/2024 (1ª parte) e 24/11/2024 (trabalho completo) até às 23:00 pelo Canvas

Valor: 35 pontos

Penalidade por atraso: Valor total, não se admite atraso!

Descrição:

A esteatose hepática, também conhecida como “fígado gorduroso”, é uma condição caracterizada pelo acúmulo anormal de gordura no fígado. A esteatose hepática não alcoólica (NAFLD) é a forma mais comum de fígado gorduroso e não está associada ao consumo excessivo de álcool. Sua prevalência tem aumentado em todo o mundo nas últimas décadas, em grande parte devido à epidemia de obesidade e síndrome metabólica. Ela afeta tanto adultos quanto crianças e está associada a condições como diabetes tipo 2, resistência à insulina e obesidade. A estimativa é que cerca de 25% da população mundial tenha NAFLD (<https://educa.cetrus.com.br/esteatose-hepatica/>). Embora a biopsia seja o padrão-ouro para o diagnóstico, exames de ultrassom que são menos invasivos podem ser usados para essa finalidade.

Neste trabalho você implementará um sistema auxiliar ao diagnóstico da NAFLD a partir da análise de exames de ultrassom. Um exemplo de imagem é mostrado na Fig. 1. A descrição da base de dados utilizada está disponível em Byra et al. (2018).




Fig. 1 Exemplo de exame de ultrassom do fígado.



PUC Minas Pontifícia Universidade Católica de Minas Gerais

ICEI - Curso de Ciência da Computação

Disciplina: Processamento e Análise de Imagens

Prof. Alexei Machado

Especificações gerais:

- a) O programa deve ser implementado em C++, Python ou Java, EM UM ARQUIVO FONTE ÚNICO compilável. Notebooks não são aceitos.
- b) O trabalho deve ser feito em grupos de 2 ou 3 componentes, cujos nomes devem ser informados nas planilhas:
 - **Campus Lourdes:**
<https://docs.google.com/spreadsheets/d/11blwde891gWPDakHzWekodnFZbXZ7K4iDxzcpdkSfS0/edit?usp=sharing>
 - **Campus Coração Eucarístico:**
https://docs.google.com/spreadsheets/d/13KB5RBTIDkkRt9an-vbLVvg3BaORwXKJFgJmDZ-P_ds/edit?usp=sharing
- c) É permitido o uso de funções elementares de bibliotecas. Por função elementar entende-se uma função básica de manipulação de imagens, cujo resultado não seja a solução final do problema. Ex: leitura de arquivos, cálculo de histogramas, filtros, cálculo de distâncias, conversão entre formatos de imagens, cálculo de características, classificadores, inclusive modelos pré-treinados. O código principal que utiliza as funções deve ser original do grupo. Não é permitido uso de geradores de código baseados em IA. O nome dos componentes deve aparecer como comentário no início do arquivo-fonte.
- d) O trabalho exige um pré-processamento dos dados que também deve ser feito exclusivamente pelos componentes do grupo.

1a etapa:

Para a especificação desta etapa, calcule o seguinte número:

$NT = (\text{soma dos números de matrícula dos componentes do grupo}) \bmod 4$

Nesta etapa os dados usados no treinamento e teste dos classificadores devem ser gerados a partir do arquivo de dados disponibilizado (dataset_liver_bmodes_steatosis_assessment_IJCARS.mat), bem como a interface gráfica do sistema. O arquivo possui 10 imagens para cada um dos 55 pacientes do estudo, cada imagem com 434×636 pixels e 8 bits por pixel.

1) Implemente um ambiente totalmente gráfico com um **menu** para as seguintes funcionalidades:

- Menu para ler e visualizar imagens no formato do arquivo (.mat) e nos formatos PNG e JPG. As imagens podem ter qualquer resolução. O histograma de tons de cinza deve ser calculado e exibido.
- Menu para recortar regiões de interesse (ROIs) de uma imagem



PUC Minas Pontifícia Universidade Católica de Minas Gerais

ICEI - Curso de Ciência da Computação

Disciplina: Processamento e Análise de Imagens

Prof. Alexei Machado

- Menu para ler e visualizar as ROIs geradas e respectivos histogramas.
 - Menu para computar as matrizes de co-ocorrência (GLCM) de uma ROI e respectivos descritores de textura, mostrando os valores calculados;
 - Menu para caracterizar as ROIs através do descritor de textura sorteado para o grupo em função de NT, mostrando os valores calculados.
 - Menu para classificar uma imagem através das técnicas selecionadas para o grupo, indicando qual a classe encontrada.
- 2) Implemente a funcionalidade de leitura e exibição das imagens em tons de cinza com opção de zoom e respectivos histogramas.
 - 3) Implemente a funcionalidade de leitura e exibição das ROIs com opção de zoom e respectivos histogramas.
 - 4) Implemente a funcionalidade de geração de uma ROI. Recorte 2 ROIs de 28x28 pixels em cada imagem. A primeira região deve ser do fígado e a segunda do córtex renal. O quadrado deve ser definido com o mouse e mostrado em cor verde. Veja como localizar as regiões na seção de Materiais e Métodos do artigo (Figura 2). A ROI do rim servirá como referência para a normalização da ROI do fígado, reduzindo diferenças entre imagens adquiridas com equipamentos distintos ou a influência de artefactos. Após o recorte, calcule e exiba o valor do índice hepatorenal HI, definido como a razão entre a média de tons de cinza da ROI do fígado e a média dos tons de cinza da ROI do rim. Ajuste os tons de cinza da ROI do fígado, multiplicando cada valor de tom de cinza pelo HI calculado. Arredonde os valores e salve a ROI do fígado em um diretório (A ROI do rim não precisa ser salva). O nome da imagem deve ser da forma ROI_nn_m, onde *nn* é o número do paciente (00 a 54) e *m* o número da imagem de ultrassom (0 a 9).
 - 5) Gere as ROIs para o dataset, seguindo o descrito no item anterior (550 ROIs). Armazene, em uma planilha csv, o nome do arquivo, classe (pacientes 0 a 16 são saudáveis e o restante possui esteatose), canto superior esquerdo das ROIs do fígado e rim, e HI.
 - 6) Calcule 4 GLCM radiais C_i onde $i=1,2,4,8$ pixels, para cada ROI.
 - 7) Calcule os descritores de Haralick Entropia e Homogeneidade para as GLCM do item anterior (4*2 características) para cada ROI.
 - 8) Conforme o valor de NT, calcule:
 - Statistical Feature Matrix (SFM): coarseness, contrast, periodicity e roughness, se NT=0
 - Local Binary Pattern (LPB) energia e entropia com raios=1,2,4,8, se NT=1
 - Momentos invariantes de Hu, se NT=2



PUC Minas Pontifícia Universidade Católica de Minas Gerais

ICEI - Curso de Ciência da Computação

Disciplina: Processamento e Análise de Imagens

Prof. Alexei Machado

- Descritores de Tamura: coarseness, contrast, directionality, line-likeness, regularity, e roughness, se $NT=3$
- 9) Armazene em uma planilha csv o nome do arquivo, classe e as características calculadas, para uso no classificador.

2a etapa: Para a especificação desta etapa, calcule os seguintes números:

$NC = (\text{soma dos números de matrícula dos componentes do grupo}) \bmod 2$

$ND = (\text{soma dos números de matrícula dos componentes do grupo}) \bmod 5$

Se $NC=0$, o classificador raso será o SVM, senão será o XGBoost.

Se $ND=0$, o classificador profundo será a ResNet50 senão se $ND=1$ será a EfficientNet, senão se $ND=2$ será a MobileNet, senão se $ND=3$ será a Inception senão se $ND=5$ será a VGG16.

Utilize sempre a última versão da rede, ou a mais recente que consiga ser carregada na memória disponível.

- 1) Separe os dados em 2 conjuntos: o conjunto de teste deve ter as 10 imagens de um dos pacientes e o conjunto de treino as demais. Após treinar e testar os classificadores com essa divisão, escolha o próximo paciente para ser o conjunto de teste. O processo deve ser repetido 55 vezes (validação cruzada).
- 2) Implemente o classificador binário raso para o problema, conforme NC. Avalie as médias de acurácia, especificidade e sensibilidade, e mostre a matriz de confusão após a validação cruzada. As características usadas como entrada para os classificadores devem ser os descritores de Haralick e os sorteados conforme NT.
- 3) Implemente o classificador profundo para o problema, conforme ND. Ajuste os pesos já disponíveis nas bibliotecas que foram treinados com o ImageNet (fine tuning). Avalie a acurácia e mostre as matrizes de confusão de cada uma após validação cruzada. Plote os gráficos de aprendizado médios (acurácia de treino e teste após cada época). As entradas para os classificadores são as ROIs recortadas.
- 4) Compare os resultados obtidos entre as soluções.



PUC Minas Pontifícia Universidade Católica de Minas Gerais

ICEI - Curso de Ciência da Computação

Disciplina: Processamento e Análise de Imagens

Prof. Alexei Machado

5) A documentação **EM FORMATO LATEX E PDF CORRESPONDENTE** deve ser na forma de um artigo com estilo da SBC, contendo:

- a) A descrição do problema.
- b) Descrição das técnicas implementadas para a solução, principalmente dos classificadores e características.
- c) Descrição dos dados
- d) As referências das bibliotecas utilizadas na implementação.
- e) As medidas de tempo de execução para diversas imagens, descritores e hiperparâmetros do classificador.
- f) Análise comparativa dos resultados obtidos nos testes, exemplos de erros e acertos dos métodos.
- g) Referências bibliográficas.

O que entregar:

Arquivo-fonte, planilhas e documentação em formato PDF e Latex. Coloque os arquivos na raiz de um diretório cujo nome deve ser o código do grupo fornecido pelo professor (Gnn). Comprima o diretório e poste no Canvas (link em drive não serve) até a hora especificada. **APENAS UM DOS COMPONENTES DEVE SUBMETER.** O tamanho total dos arquivos não deve ultrapassar 8 Mbytes. **NÃO INCLUA A BASE DE DADOS! TABALHOS MAIORES QUE 8 MB NÃO SERÃO CORRIGIDOS.**

Obs: Trabalhos de qualidade superior poderão ganhar pontos extras.

ATENÇÃO - Causas da anulação da nota do trabalho:

- a) Trabalhos entregues fora do prazo;
- b) Trabalhos copiados de qualquer fonte, reaproveitados de outros semestres, em parte ou totalidade, ou gerados por Inteligência Artificial, receberão nota 0 (zero), independente de quem lesou ou foi lesado. É responsabilidade do grupo manter o sigilo sobre seu trabalho. O trabalho deve ser realizado exclusivamente pelos componentes do grupo, sem auxílio de terceiros. No caso de uso do GitHub, deixe o repositório em modo privado. É permitido apenas o uso de funções de bibliotecas, mas o código que chama as funções deve ser original do grupo. No caso de detecção de cópia em um módulo, todos os módulos anteriores terão suas notas alteradas para 0 (zero);
- c) ROIs copiadas de outros grupos;
- d) Ausência de documentação;
- e) Arquivos maiores que o limite de tamanho.



PUC Minas Pontifícia Universidade Católica de Minas Gerais
ICEI - Curso de Ciência da Computação
Disciplina: Processamento e Análise de Imagens
Prof. Alexei Machado

Artigo de referência:

BYRA, Michał et al. Transfer learning with deep convolutional neural network for liver steatosis assessment in ultrasound images. **International journal of computer assisted radiology and surgery**, v. 13, p. 1895-1903, 2018.

Exemplo de código Python para leitura do arquivo .mat:

Este código foi adaptado de <https://www.kaggle.com/datasets/shanecandoit/dataset-of-bmode-fatty-liver-ultrasound-images/code>. É um notebook para rápida prototipação. Observe que o trabalho deve ser um arquivo-fonte único e independente. Os grupos que usarem C e Java podem ler o arquivo e salvar em outro formato.

```
import os # operating system functionalities

from pathlib import Path # for handling paths conveniently

import scipy.io # load the data according to the instructions in the
data sheet

import numpy as np # images are numpy.ndarrays
import matplotlib.pyplot as plt # for plotting the images

# definir nome do diretório

path_input_dir = Path("/Users/alexei/downloads/liver")
path_data = path_input_dir /
"dataset_liver_bmodes_steatosis_assessment_IJCARS.mat"

# carregar dados
data = scipy.io.loadmat(path_data)

# acessar as imagens de 'data'

data_array = data['data']
images = data_array['images']

# Acesso à imagem m do paciente n

# n varia de 0 a 54, m de 0 a 9
```



PUC Minas Pontifícia Universidade Católica de Minas Gerais
ICEI - Curso de Ciência da Computação
Disciplina: Processamento e Análise de Imagens
Prof. Alexei Machado

```
n=1  
  
m=5  
  
imagem = images[0][n][m]  
  
print(imagem.shape)  
  
# plotar a imagem  
  
plt.figure(figsize=(9,9))  
  
plt.imshow(first_image, cmap='gray') # Use 'gray' for grayscale  
images  
  
plt.axis('off') # Hide axes for better visualization  
  
plt.show()
```